

TRABAJO DE FIN DE GRADO

Análisis del desequilibrio entre los precios de la vivienda en alquiler y los salarios de los jóvenes en España (2011–2024): un enfoque provincial, explicativo y predictivo

Imbalance between rental prices and young people's wages in Spain (2011–2024): a provincial, explanatory and predictive approach

Entrega: Análisis del Dato

Alumna: María de la Concepción Díez de Rivera de Solís

Email: mcdiezderiveradesolis@gmail.com

Tutor: Rufino Prieto Alonso

Grado en Business Analytics

Curso académico 2025–2026 · Convocatoria extraordinaria

Resumen y contexto

Para situar el pilar de Análisis del Dato, se sintetizan a continuación las secciones de la memoria que lo preceden.

La población joven española se emancipa entre las más tardías de la Unión Europea, y el coste del alquiler es uno de sus determinantes centrales. Este Trabajo Fin de Grado cuantifica y explica el desequilibrio entre el precio del alquiler y el salario de la población joven en España a escala provincial, sobre las 48 unidades territoriales de régimen fiscal común (46 provincias y las ciudades autónomas de Ceuta y Melilla) durante el periodo 2011–2024, con una proyección de escenario para 2025–2027. La resolución provincial constituye la aportación diferencial frente al seguimiento institucional disponible (Consejo de la Juventud de España, 2025; INJUVE, 2025; Eurostat, 2024), de carácter descriptivo y de alcance nacional o autonómico.

El indicador central es la tasa de esfuerzo, definida como el cociente entre el alquiler mensual y el salario neto mensual estimado de la población joven, tomando como banda de referencia la de 26 a 35 años (fase central de la emancipación), y contrastada con el umbral del 30 % como referencia de asequibilidad. La pregunta de investigación es cuál es la magnitud de ese desequilibrio a escala provincial, cómo varía entre provincias y en el tiempo, y qué escenarios cabe proyectar. Se concreta en tres subpreguntas, cada una asociada a una familia de técnica analítica: qué variables se asocian al precio del alquiler, cómo se agrupan las provincias según su (in)asequibilidad, y hacia dónde evoluciona la tasa de esfuerzo. El objetivo general es, por tanto, cuantificar y explicar el desequilibrio e identificar sus determinantes, sus patrones territoriales y su trayectoria, para aportar una perspectiva explicativa y predictiva que complemente el seguimiento descriptivo existente.

El trabajo se organiza en tres pilares. La ingeniería del dato construye, a partir de fuentes oficiales (alquiler del SERPAVI, salario joven de la Agencia Tributaria, y variables de control como el paro de la Encuesta de Población Activa, el IPC y el salario mínimo), un panel provincial integrado y reproducible. El análisis del dato, que se desarrolla en este documento, cuantifica el desequilibrio, identifica los determinantes del alquiler mediante la comparación de varios modelos, clasifica las provincias en tipologías y proyecta la tasa de esfuerzo. El análisis de negocio traduce después los hallazgos en conclusiones y recomendaciones. La literatura previa comparte la medida del esfuerzo y el umbral del 30 % como referencia de asequibilidad y aborda el fenómeno desde el seguimiento descriptivo nacional o autonómico; este trabajo se sitúa en la tradición de los precios hedónicos (Rosen, 1974) y aporta el análisis provincial, explicativo y predictivo que ese seguimiento no cubre.

Índice de la memoria final

1. Introducción

2. Objetivos

3. Estudio bibliográfico

4. Ingeniería del Dato

5. Análisis del Dato

5.1. Marco teórico

5.2. Punto de partida, variable objetivo y estrategia de validación

5.3. Modelo supervisado: determinantes del precio del alquiler

5.4. Modelo no supervisado: tipologías provinciales con K-Means

5.5. Series temporales: escenario del esfuerzo con ARIMA

5.6. Robustez y adecuación de los modelos

5.7. Resumen de resultados

5.8. Interpretación de resultados

5.9. Conclusiones del análisis y enlace con el análisis de negocio

6. Análisis de Negocio

7. Conclusiones, limitaciones y propuestas de trabajo futuro

8. Bibliografía

9. Anexos

Índice de tablas

Tabla 1. Paneles de datos utilizados y su función en el análisis.....	4
Tabla 2. Variables del modelado con su tipo y función (versión orientada a modelado).....	7
Tabla 3. Comparación de los modelos de regresión: R^2 dentro y fuera de muestra (validación temporal).....	9
Tabla 4. Determinantes del alquiler por efectos fijos provinciales (LSDV) con errores estándar clusterizados por provincia.....	10
Tabla 5. Aportación incremental de los determinantes sobre la identidad provincial (R^2 fuera de muestra).....	14
Tabla 6. Provincias con mayor desviación del alquiler respecto a sus fundamentales (2024).....	16

Índice de figuras

Figura 1. Flujo metodológico del Análisis del Dato.....	6
Figura 2. Curva del R^2 fuera de bolsa del Random Forest.....	8
Figura 3. Matriz de correlación de la variable objetivo y los determinantes.....	10
Figura 4. Diagnóstico del modelo Ridge: (a) predicho frente a observado, (b) residuos, (c) coeficientes estandarizados.....	11
Figura 5. Tipologías provinciales (K-Means, $k = 3$).....	12
Figura 6. Escenario de la tasa de esfuerzo 2025–2027 (ARIMA).....	13

5. Análisis del Dato

5.1. Marco teórico

La metodología se fundamenta antes de aplicarla, de modo que cada técnica se justifica por su ajuste a la naturaleza del problema y del dato, y no como un procedimiento opaco aplicado sin justificación. Las tres subpreguntas de investigación, qué determina el alquiler, cómo se agrupan los territorios y hacia dónde evoluciona el esfuerzo, se corresponden con tres familias metodológicas: el aprendizaje supervisado, el aprendizaje no supervisado y los modelos de series temporales. La elección de cada una se deriva de la estructura de los datos, que se describe a continuación en términos generales, sin anticipar los resultados.

5.1.1. Naturaleza del problema y de los datos

Los datos forman un panel longitudinal: las mismas 48 provincias observadas en años sucesivos (Baltagi, 2008; Wooldridge, 2010). Esta estructura tiene dos rasgos que condicionan todo el diseño. El primero es que las observaciones de una misma provincia no son independientes entre sí, porque los valores de un año influyen en los del siguiente, y que la muestra efectiva es pequeña. De ahí se siguen tres decisiones. La primera es usar modelos sencillos y regularizados, es decir, con pocos parámetros y con un mecanismo que evite el sobreajuste, porque un modelo demasiado complejo sobre pocos datos tiende a memorizar el ruido en lugar de aprender el patrón. La segunda es tratar la diferencia estructural entre territorios con efectos fijos de provincia, esto es, dejar que cada provincia tenga su propio nivel de partida, para no confundir esas diferencias de base con el efecto de las variables que sí se estudian. La tercera es validar respetando el orden del tiempo: se entrena con los años más antiguos y se evalúa en los más recientes, nunca con una partición aleatoria que mezcle pasado y futuro, que daría al modelo información de la que en la realidad no dispondría. El segundo rasgo es que la serie temporal es corta, solo catorce años, lo que obliga a tratar la proyección como un escenario y no como una predicción exacta. Por último, la variable que se modela es el precio del alquiler: la elección se apoya en el enfoque hedónico (Rosen, 1974), según el cual el valor de un bien se explica por sus atributos y su entorno, y responde además a que el alquiler es el componente que más pesa en la tasa de esfuerzo.

5.1.2. Aprendizaje supervisado: regresión y conjuntos de árboles

La metodología exige plantear al menos dos modelos que compitan sobre el mismo problema, un modelo base, simple e interpretable, frente a modelos avanzados más flexibles, con las mismas variables y la misma partición temporal, y seleccionar el ganador por su error fuera de muestra (James et al., 2013). Este diseño responde no solo a qué modelo predice mejor, sino a por qué, y protege frente al sesgo de preferir la complejidad cuando el volumen de datos es reducido.

El modelo base es la regresión lineal, que expresa la variable objetivo como una suma ponderada de las variables explicativas y se estima por mínimos cuadrados; se elige como punto de partida porque sus coeficientes tienen una lectura económica directa. La estimación ordinaria busca los coeficientes que minimizan la suma de los cuadrados de los residuos, $\sum (y_i - \hat{y}_i)^2$, donde y_i es el valor observado y $\hat{y}_i$ el predicho. Su problema en este panel es la fuerte correlación entre los predictores salariales, que infla la varianza de los coeficientes y los vuelve inestables. La regresión Ridge (Hoerl y Kennard, 1970) lo corrige añadiendo a esa función un término de penalización proporcional a la suma de los coeficientes al cuadrado, $\sum (y_i - \hat{y}_i)^2 + \lambda \cdot \sum \beta_j^2$; el hiperparámetro λ gradúa cuánto se penaliza, de modo que cuanto mayor es, más se encogen los coeficientes hacia cero. Esa penalización introduce un sesgo pequeño a cambio de reducir mucho la varianza, lo que estabiliza la estimación cuando los regresores están correlacionados y mejora la capacidad de generalizar (Hastie et al., 2009). Existe una alternativa, Lasso (Tibshirani, 1996), que penaliza el valor absoluto de los coeficientes y llega a anular algunos; aquí se prefiere Ridge porque el objetivo es conservar y estabilizar todo el conjunto de determinantes, no quedarse con un subconjunto.

Los modelos avanzados son conjuntos de árboles, que combinan muchos árboles de decisión (Breiman et al., 1984), y se eligen los dos representantes de sus dos grandes familias para que la comparación las cubra ambas. El Random Forest (Breiman, 2001) sigue la estrategia del bagging (Breiman, 1996): entrena numerosos árboles, cada uno sobre una muestra distinta extraída al azar de los datos (con reemplazo) y usando solo una selección aleatoria de variables en cada corte, y luego promedia sus predicciones; esa doble aleatoriedad reduce la varianza y le permite captar relaciones no lineales sin definirlas de antemano, y de paso ofrece una estimación de su rendimiento sobre las observaciones que cada muestra deja fuera (out-of-bag) y una medida de la importancia de cada variable. El Gradient Boosting (Friedman, 2001) sigue la estrategia contraria, el boosting: en lugar de promediar árboles independientes, los añade uno tras otro, de manera que cada árbol nuevo corrige el error que dejó el conjunto anterior; alcanza mucha precisión, pero a costa de más ajustes finos y de un mayor riesgo de sobreajuste cuando hay pocos datos. Los dos comparten una propiedad decisiva para este trabajo: no extrapolan, esto es, no predicen valores fuera del rango que vieron al entrenarse, porque sus predicciones son promedios de los datos observados. Ante una serie con tendencia como el alquiler, eso les lleva a quedar por debajo en los años futuros, mientras que un modelo lineal sí prolonga la pendiente. Estos métodos se han aplicado con éxito a la predicción de precios de vivienda, también en mercados europeos y regionales (Tchente y Nyawa, 2022; Soltani y Lee, 2024), aunque su ventaja sobre los modelos lineales no es universal, sino que depende del conjunto de datos.

5.1.3. Aprendizaje no supervisado: agrupamiento K-Means

La dimensión geográfica se aborda con el algoritmo K-Means (MacQueen, 1967; Lloyd, 1982). Este método reparte las unidades en k grupos buscando que, dentro de cada grupo, las observaciones se

parezcan lo más posible; en términos técnicos, minimiza la suma de distancias al cuadrado de cada provincia al centro de su grupo. Se elige por ser el método de agrupamiento más habitual, eficiente y fácil de interpretar, y porque encaja con un problema pequeño: 48 provincias descritas por solo dos rasgos. Frente a otras opciones (el agrupamiento jerárquico, que aquí se usa solo como prueba de robustez, o los métodos basados en densidad o en mezclas), no añade complejidad que no haga falta. Antes de agrupar, las dos variables se estandarizan para que ninguna pese más que la otra solo por su escala. A diferencia de la regresión, agrupar no es un problema de predicción y no hay un modelo ganador: para juzgar si la partición es buena se usa el coeficiente de silueta (Rousseeuw, 1987), que mide a la vez lo compactos que son los grupos y lo separados que están entre sí. El número de grupos se decide combinando esa medida con lo interpretables que resultan las tipologías y con una comprobación de robustez frente a otro método de agrupamiento.

5.1.4. Series temporales: modelos ARIMA y estacionariedad

La proyección temporal se aborda con la familia ARIMA (Box y Jenkins, 1976), que predice una serie a partir de su propio pasado mediante tres componentes: uno autorregresivo (la serie depende de sus valores anteriores), uno de integración o diferenciación (se trabaja con los cambios de un año a otro, no con los niveles) y uno de media móvil (los errores pasados también informan). Sus tres órdenes, (p, d, q), dan nombre a cada especificación ARIMA(p, d, q). El método exige que la serie sea estacionaria, es decir, que su media y su variabilidad no cambien con el tiempo; esto se comprueba con la prueba de Dickey-Fuller aumentada (Dickey y Fuller, 1979), y si la serie no lo es, se diferencia (se toman los cambios interanuales) hasta que lo sea. Dos cautelas guían su uso. La primera: al ser datos anuales, no hay estacionalidad, de modo que no se incluye ningún componente estacional. La segunda: con una serie corta, tanto la prueba como la estimación son poco fiables (Hyndman y Athanasopoulos, 2018), por lo que la proyección se presenta como un escenario con intervalos amplios, con la especificación más sencilla posible y validada con una prueba sobre los últimos años. Dentro de los modelos univariantes se prefiere ARIMA al suavizado exponencial porque trata de forma explícita la diferenciación que la serie necesita y porque permite la forma más simple de todas, un paseo aleatorio con deriva (un solo parámetro), mientras que un suavizado con tendencia estimaría varios parámetros sobre solo 14 datos.

5.1.5. Medidas de adecuación y validación

La calidad de los modelos se mide con varias métricas que se complementan, porque ninguna basta por sí sola (Hyndman y Koehler, 2006). El error absoluto medio (MAE) es la media de los errores en valor absoluto, $MAE = (1/n) \cdot \sum |y_i - \hat{y}_i|$, y dice cuánto se equivoca el modelo de media, en las unidades de la variable. La raíz del error cuadrático medio (RMSE) es la raíz de la media de los errores al cuadrado, $RMSE = \sqrt{(1/n) \cdot \sum (y_i - \hat{y}_i)^2}$; al elevar al cuadrado, castiga más los errores grandes y siempre es mayor o igual que el MAE. El error porcentual absoluto medio (MAPE) mide el error en términos relativos, $MAPE = (100/n) \cdot \sum |y_i - \hat{y}_i|/|y_i|$, lo que permite comparar series de distinta escala. Y el coeficiente de

determinación (R^2) indica qué parte de la variación del alquiler explica el modelo: vale como mucho uno (ajuste perfecto) y puede ser negativo fuera de muestra si el modelo predice peor que usar simplemente la media. Todas se calculan fuera de muestra. El agrupamiento se evalúa con el coeficiente de silueta, y la serie temporal, además, con el error de la prueba sobre los últimos años. El R^2 se reporta con honestidad: si resulta modesto, no se ensaya después un modelo que lo eleve, sino que se interpreta como un dato real sobre el fenómeno o sobre el tamaño de la muestra.

5.2. Punto de partida, variable objetivo y estrategia de validación

El análisis del dato parte del panel provincial depurado y certificado en la fase de ingeniería del dato, que no se reconstruye: se carga y se analiza. El panel principal reúne 672 observaciones (48 unidades territoriales por 14 años) con 30 variables y es el que sostiene tanto el modelado supervisado como la inferencia; el modelado utiliza 624 observaciones, ya que el año base 2011 se descarta por carecer de los valores rezagados (lag-1) que requieren algunos predictores. Se emplean además dos conjuntos auxiliares, cada uno con una función bien delimitada. El panel por edad (2.016 observaciones, las provincias y los años desagregados en tres bandas de edad) sirve para medir el gradiente del esfuerzo entre bandas de edad, esto es, cuánto difiere la carga del alquiler según la edad. Y la serie de población joven por provincia (576 observaciones, disponible hasta 2022) permite dimensionar la exposición territorial al problema, es decir, qué proporción de jóvenes vive en provincias con un esfuerzo por encima del umbral. De este modo, cada panel responde a una pregunta distinta y no se mezclan en el modelo principal.

Tabla 1. Paneles de datos utilizados y su función en el análisis. Fuente: elaboración propia.

Panel	Observaciones	Cobertura	Función en el análisis
Panel principal	672 (48 prov. × 14 años); 624 en el modelado	30 variables, 2011–2024	Modelado supervisado e inferencia sobre el alquiler
Panel por edad	2.016 (× 3 bandas de edad)	2011–2024	Gradiente del esfuerzo entre bandas de edad
Población joven	576	Por provincia, hasta 2022	Exposición territorial: jóvenes en provincias sobre el umbral

La primera decisión es qué variable se modela. Se toma el alquiler mediano provincial, y no directamente la tasa de esfuerzo, por dos razones. La primera es metodológica: la tasa de esfuerzo es, por construcción, el cociente entre alquiler y salario, así que modelarla con esas mismas variables sería circular. La segunda es empírica: la tasa de esfuerzo se asocia mucho más con el alquiler (correlación de 0,63) que con el salario (correlación de -0,20), por lo que explicar el precio del alquiler concentra la parte más informativa del esfuerzo y evita esa circularidad.

La segunda decisión es plantear el problema como una regresión (predecir un número, el alquiler) y no como una clasificación (decidir asequible o no asequible). Clasificar según el umbral del 30 % no tendría sentido aquí: el 95,8 % de las observaciones (644 de 672) ya está por encima del umbral y solo 4 de las

48 provincias cambian de lado en todo el periodo, de manera que un clasificador apenas tendría casos distintos que aprender. Por eso tampoco se usan la matriz de confusión ni la curva ROC, propias de la clasificación. Además, antes de modelar se eliminan los predictores que son el propio alquiler o derivan de él (el alquiler por metro cuadrado, cuya correlación con el alquiler mediano es de 0,976; la superficie; el alquiler real; la propia tasa de esfuerzo y el indicador de umbral), para evitar la fuga de información.

La tercera decisión es cómo validar el modelo. Como los datos son un panel y los años de una misma provincia están relacionados, no se usa una partición aleatoria: mezclar años al azar dejaría que el modelo aprendiera con información del futuro y se evaluara sobre el pasado, lo que infla artificialmente su rendimiento (un sesgo llamado fuga de información). En su lugar se valida respetando el orden del tiempo: se entrena con los años más antiguos y se evalúa en los más recientes, igual que ocurriría en la realidad, donde el modelo predice ejercicios todavía no observados. El esquema principal es una validación de ventana expansiva entre 2018 y 2024, con siete particiones fuera de muestra (cada año se predice habiendo entrenado solo con los anteriores), y se reserva además 2024 como último año de prueba. Frente a la validación cruzada de pliegues aleatorios, la ventana expansiva es la única coherente con una serie que tiene tendencia, porque nunca usa un año futuro para entrenar un modelo que se juzga sobre un año pasado. Para evitar otra fuga más sutil, la estandarización que necesita Ridge se calcula solo con el tramo de entrenamiento de cada partición y luego se aplica al de evaluación, con lo que la transformación no incorpora información del periodo evaluado. Como prueba de robustez, elegir el hiperparámetro de Ridge usando solo ventanas hasta 2023 da el mismo valor, así que la conclusión no depende de incluir 2024.

Conviene comprobar de forma explícita que el tamaño de la muestra respalda cada modelo, porque eso marca qué es defendible. Los tres modelos supervisados (Ridge, Random Forest y Gradient Boosting) se entrenan sobre las mismas 624 observaciones frente a una decena de determinantes más los efectos fijos de provincia: holgura suficiente para un modelo lineal regularizado y para conjuntos de árboles que se validan con remuestreo. El modelo de inferencia con efectos fijos se estima sobre esas mismas 624 observaciones, con 48 grupos (uno por provincia) para los errores clusterizados, número holgado para una inferencia robusta. El K-Means ordena 48 provincias sobre dos rasgos, una dimensión baja y adecuada para una partición interpretable en tres grupos. El ARIMA es el caso más justo, con solo 14 observaciones anuales: bastan para una especificación muy sencilla tratada como escenario, pero descartan órdenes muy parametrizados y modelos intensivos en datos como las redes neuronales.




Figura 1. Flujo metodológico del Análisis del Dato. Fuente: elaboración propia.

5.3. Modelo supervisado: determinantes del precio del alquiler

5.3.1. Planteamiento: una competición entre un modelo base y dos avanzados

Sobre el problema de explicar el alquiler mediano se enfrentan el modelo base, la regresión Ridge, y los dos modelos avanzados de conjunto de árboles, el Random Forest y el Gradient Boosting, cuyo fundamento se ha descrito en el marco teórico. La comparación se realiza en dos encuadres del mismo problema: uno de determinantes, en el que el alquiler se explica a partir de variables estructurales del año en curso, y uno autorregresivo, que añade el alquiler del año anterior como referencia de persistencia. Ambos encuadres comparten variables, partición y métricas, de modo que las diferencias de rendimiento son atribuibles al modelo y no al diseño.

5.3.2. Especificación y calibración de los modelos

Los tres modelos se ajustan sobre la misma matriz de 624 observaciones por 59 columnas (los determinantes, más una variable indicadora por provincia y la tendencia anual), ya depurada de cualquier variable que filtre información del alquiler; la Tabla 2 detalla esas variables con su tipo y su función. Ningún hiperparámetro se fija a mano, sino por validación. En Ridge, el parámetro de regularización se valida sobre la ventana expansiva y sale 10, el valor que minimiza el error fuera de muestra. En el Random Forest, la profundidad de los árboles y el tamaño mínimo de hoja se eligen por su rendimiento

sobre las observaciones que cada muestra deja fuera (out-of-bag), que favorece árboles sin límite de profundidad y hojas de una sola observación, y el número de árboles se fija mirando la curva de ese rendimiento (Figura 2): apenas mejora a partir de un centenar, así que se adoptan 300 por prudencia. En el Gradient Boosting, el número de etapas se elige también por validación, con una tasa de aprendizaje de 0,05 y árboles poco profundos (profundidad 3), lo que da un modelo de 500 etapas.

Tabla 2. Variables del modelado con su tipo y función (versión orientada a modelado). Fuente: elaboración propia.

Variable	Tipo	Rol en el modelo
alquiler_mediano	Numérica continua (€/mes)	Variable objetivo
n_contratos	Numérica de recuento	Determinante: actividad del mercado de alquiler
neto_mes_18_25	Numérica continua (€/mes)	Determinante: salario neto 18-25 años
neto_mes_26_35	Numérica continua (€/mes)	Determinante: salario neto 26-35 años
neto_mes_36_45	Numérica continua (€/mes)	Determinante: salario neto 36-45 años
neto_mes_18_34	Numérica continua (€/mes)	Determinante: salario neto 18-34 años
paro_total	Numérica continua (%)	Determinante: tasa de paro
smi_mes	Numérica continua (€/mes)	Determinante: salario mínimo interprofesional
D_2021	Binaria (0/1)	Indicadora del efecto temporal de 2021
neto_mes_26_35_lag1	Numérica continua (€/mes)	Determinante rezagado (persistencia)
paro_total_lag1	Numérica continua (%)	Determinante rezagado del paro
var_salario_pct	Numérica continua (%)	Determinante: variación salarial interanual
Indicadoras de provincia (47)	Binarias (0/1)	Efectos fijos de provincia
Tendencia anual	Numérica (año)	Control de tendencia temporal




Figura 2. Curva del R^2 fuera de bolsa del Random Forest. Fuente: elaboración propia.

5.3.3. Comparación, selección del modelo y mecanismo

El modelo se elige por su rendimiento fuera de muestra, promediado sobre las siete ventanas de la validación expansiva (Tabla 3). En el encuadre de determinantes, Ridge obtiene un R^2 de 0,937, frente al 0,732 del Gradient Boosting y el 0,609 del Random Forest, y además el menor error absoluto medio (16,1 €) y la menor raíz del error cuadrático medio (21,4 €) de los tres. En el encuadre autorregresivo, en cambio, las diferencias casi desaparecen (0,970 Ridge, 0,968 Gradient Boosting, 0,959 Random Forest), porque el alquiler del año anterior ya aporta el nivel y ningún modelo necesita extrapolar.

La Tabla 3 separa además el R^2 dentro de muestra (en los datos de entrenamiento) del de fuera de muestra, y ahí está la prueba cuantitativa del fenómeno. Los dos modelos de árboles ajustan el entrenamiento casi a la perfección (R^2 próximo a 0,99), pero su rendimiento cae con claridad fuera de muestra, hasta 0,609 en el Random Forest; Ridge, en cambio, mantiene un ajuste alto y estable dentro y fuera (0,980 y 0,937). Esa distancia entre el entrenamiento y la validación es la señal del sobreajuste: los árboles se ciñen a los valores observados pero no proyectan más allá de su rango, mientras que el lineal regularizado generaliza.

Ese contraste es la clave técnica del pilar y se explica por la propiedad ya enunciada de los árboles: no extrapolan fuera del rango visto en el entrenamiento. En 2024 una sola provincia, Madrid (800 €), supera el techo de ese rango (759 €): Ridge la sigue de cerca (781 €), mientras que el Random Forest y el Gradient Boosting se quedan por debajo del techo (734 € y 725 €); este contraste entre el modelo que sigue a Madrid y los que se quedan bajo el techo se visualiza en la Figura 4, panel a. La conclusión, coherente con el tamaño del panel y con la validación temporal, es que aquí el modelo sencillo y regularizado generaliza mejor que el complejo. El modelo explicativo final es, por eso, la regresión Ridge sobre los determinantes con efectos fijos de provincia; el encuadre autorregresivo se conserva como referencia de persistencia, no como modelo explicativo, porque el alquiler rezagado absorbe la

dinámica del mercado y resta lectura a los determinantes. El análisis es explicativo-predictivo, no causal: al usar datos observacionales, se habla de variables asociadas al alquiler, no de causas.

Tabla 3. Comparación de los modelos de regresión: métricas de error (MAE, RMSE, MAPE) y R^2 dentro y fuera de muestra (validación temporal). Fuente: elaboración propia.

Modelo	MAE	RMSE	MAPE	R^2 entren.	R^2 fuera de muestra
A1 Determinantes · Ridge (base)	16,1	21,4	3,53	0,980	0,937
A1 Determinantes · Random Forest	40,2	52,9	8,74	0,989	0,609
A1 Determinantes · Gradient Boosting	30,7	42,8	6,58	0,993	0,732
A2 Autorregresivo · Ridge (base)	11,3	14,4	2,52	0,990	0,970
A2 Autorregresivo · Random Forest	12,1	16,2	2,60	0,998	0,959
A2 Autorregresivo · Gradient Boosting	11,1	14,6	2,42	0,999	0,968

5.3.4. Inferencia complementaria: efectos fijos, errores clusterizados y colinealidad

La competición predictiva permite elegir el modelo con menos error, pero no basta para leer sus coeficientes como asociaciones estables. Por eso se estima, de forma complementaria, un modelo de panel con efectos fijos de provincia mediante variables indicadoras, conocido como mínimos cuadrados con variables indicadoras o LSDV (Baltagi, 2008; Wooldridge, 2010). Este modelo controla los rasgos estructurales de cada territorio que no cambian en el tiempo y no se observan directamente, e identifica las asociaciones a partir de la variación dentro de cada provincia a lo largo de los años. Se estima con errores estándar clusterizados por provincia, es decir, robustos a que las observaciones de un mismo territorio estén correlacionadas y tengan distinta variabilidad. Como alternativas se descartan el modelo agrupado, que ignora esa heterogeneidad, y el de efectos aleatorios, que exige una condición (que el efecto no observado sea independiente de los regresores) difícil de sostener en mercados de vivienda.

El diagnóstico de colinealidad se apoya en la matriz de correlación (Figura 3) y en el factor de inflación de la varianza (VIF), que mide cuánto se infla la incertidumbre de un coeficiente por estar su variable correlacionada con otras. Las distintas medidas de salario están tan correlacionadas entre sí que sus VIF alcanzan el orden de 10^3 (el mayor, 1.349,7, en el salario neto de 26 a 35 años): sus coeficientes

individuales no se pueden separar, deben leerse en bloque, y conviene la regularización de Ridge en la parte predictiva.




Figura 3. Matriz de correlación de la variable objetivo y los determinantes. Fuente: elaboración propia.

Los determinantes estimados por efectos fijos se recogen en la Tabla 4. El único que sigue siendo significativo incluso bajo la especificación más exigente, con efectos fijos de provincia y de año, es el volumen de contratos; el salario mínimo lo es con tendencia anual, pero, como toda variable nacional, queda absorbido por los efectos de año. La capacidad explicativa del modelo inferencial es muy alta (R^2 dentro de muestra de 0,975 con efectos fijos y 0,976 con efectos de dos vías); es un ajuste de interpretación, distinto del R^2 fuera de muestra (0,937) que mide la capacidad de predicción de Ridge.

Tabla 4. Determinantes del alquiler por efectos fijos provinciales (LSDV) con errores estándar clusterizados por provincia. Fuente: elaboración propia.

Determinante	coef	EE_cluster	t	p
n_contratos (por 1.000)	0,563	0,144	3,907	<0,001
neto_mes_18_25	0,124	0,063	1,967	0,049
neto_mes_26_35	-0,028	0,237	-0,119	0,905
neto_mes_36_45	-0,075	0,104	-0,723	0,469
neto_mes_18_34	-0,096	0,197	-0,488	0,625
paro_total	0,398	0,502	0,793	0,428
smi_mes	0,130	0,026	5,077	<0,001
D_2021	13,466	6,480	2,078	0,038
neto_mes_26_35_lag1	0,256	0,304	0,842	0,400
paro_total_lag1	-0,068	0,520	-0,130	0,897

var_salario_pct	1,431	2,831	0,506	0,613
-----------------	-------	-------	-------	-------

El diagnóstico del modelo seleccionado se resume en la Figura 4, en tres paneles. El panel (a) enfrenta el alquiler predicho con el observado en el año de prueba e incluye el techo de extrapolación: se ve que solo Ridge sigue a Madrid por encima de ese techo, mientras los árboles se quedan limitados por él. El panel (b) muestra los residuos repartidos en torno a cero sin un patrón claro, lo que respalda que la forma lineal es adecuada. El panel (c) ordena los coeficientes estandarizados por su peso. En los modelos de árboles, la interpretación suele apoyarse en técnicas como los valores SHAP; aquí no hacen falta, porque el modelo elegido es lineal y esos coeficientes, junto con la inferencia de efectos fijos, ya cumplen esa función explicativa.




Figura 4. Diagnóstico del modelo Ridge: (a) predicho frente a observado, (b) residuos, (c) coeficientes estandarizados. Fuente: elaboración propia.

5.4. Modelo no supervisado: tipologías provinciales con K-Means

Las 48 provincias se agrupan según dos rasgos que resumen su comportamiento en todo el periodo: el nivel medio de la tasa de esfuerzo y su dirección, es decir, si sube o baja con los años. Se usan estos dos rasgos, y no solo el nivel, por una razón de fondo: la inasequibilidad es casi universal (el 95,8 % de las observaciones supera el umbral del 30 %), así que apenas hay provincias de esfuerzo bajo; lo que de verdad distingue a unos territorios de otros no es tener el esfuerzo alto o bajo, sino hacia dónde va. Por eso no salen tres grupos del tipo alto-medio-bajo, sino tres grupos definidos por la combinación de nivel y dirección. Los dos rasgos se estandarizan para que ninguno pese más por su escala. El número de grupos se decide combinando el coeficiente de silueta con la interpretabilidad: la silueta favorece levemente dos grupos (0,514 frente a 0,486 con tres), pero por un margen muy pequeño, y esa partición solo distinguiría las provincias de alquiler alto de las de alquiler bajo. Se adopta $k = 3$ porque su silueta es casi igual y su lectura es mucho más útil: distingue un grupo de esfuerzo alto y al alza (nivel medio del 45,9 % que además crece, +0,25 puntos por año), con las grandes metrópolis y las islas como Madrid, Barcelona o Baleares; un grupo intermedio mayoritario (35,0 %, levemente a la baja, -0,13); y un grupo de esfuerzo también alto pero en claro descenso (43,7 %, -0,43). La Figura 5 los muestra como tres

nubes separadas en un plano cuyo eje horizontal es el nivel de esfuerzo y el vertical su tendencia, lo que muestra con claridad que la diferencia clave entre grupos es la dirección, y no solo el nivel.

La dimensión poblacional añade un matiz decisivo, porque los grupos no pesan lo mismo en número de jóvenes. Cruzando las tipologías con el padrón de jóvenes de 2022, el grupo de esfuerzo alto y al alza, pese a tener solo diez provincias, concentra a la mitad de la juventud del país (el 50,5 %, 4,1 millones de jóvenes de 18 a 34 años), porque incluye las grandes ciudades; el grupo intermedio reúne al 38,2 % (3,1 millones) y el que descende, solo al 11,3 % (0,9 millones). La lectura importa: el problema más grave no se circunscribe a un área geográfica reducida, sino que se concentra precisamente en las provincias donde reside la mayoría de los jóvenes. Y la solución es robusta: un agrupamiento jerárquico independiente da casi la misma partición, con un índice de Rand ajustado de 0,86 (una medida de coincidencia entre dos agrupamientos, donde 1 sería idéntico).




Figura 5. Tipologías provinciales (K-Means, $k = 3$). Fuente: elaboración propia.

5.5. Series temporales: escenario del esfuerzo con ARIMA

Hasta aquí los modelos han explicado el precio del alquiler provincia a provincia; la última pregunta es distinta: hacia dónde irá el esfuerzo en los próximos años. Por eso esta parte cambia de objeto y de escala. De objeto, porque ahora se proyecta la tasa de esfuerzo, que es el indicador cuyo futuro importa para la decisión (si seguirá por encima del umbral del 30 %), y no el alquiler. De escala, porque la proyección se hace sobre la serie nacional agregada y no provincia a provincia: con solo catorce años por provincia, las series provinciales serían demasiado cortas e inestables, mientras que la serie nacional, al promediar, es más estable y basta para un escenario. Antes de proyectar con un modelo ARIMA hay que comprobar si esa serie es estacionaria, es decir, si su media y su variabilidad se mantienen estables en el tiempo, porque ARIMA lo exige. La prueba de Dickey-Fuller aumentada no permite descartar que

la serie tenga tendencia ($p = 0,279$), así que no es estacionaria. La solución no es renunciar a ARIMA, sino diferenciar la serie una vez: en lugar de los niveles año a año se trabaja con sus cambios de un año al siguiente, que sí son estacionarios ($p = 0,005$); esa diferenciación es precisamente la I (de integración) de ARIMA y fija su orden de integración en uno. Además, al ser datos anuales no hay estacionalidad (ningún patrón que se repita dentro del año), de modo que no se añade ningún componente estacional; conviene no confundir estacionalidad, que es repetición intraanual, con estacionariedad, que es estabilidad de la media y la variabilidad.

Queda elegir el orden del modelo. En lugar de determinarlo mediante un criterio automático, se elige el que mejor predice en una prueba retrospectiva, esto es, reservando los últimos años y midiendo el error al predecirlos. El que menos se equivoca es el más sencillo de todos: un paseo aleatorio con deriva, que en notación ARIMA es un ARIMA(0,1,0) con término constante. Un paseo aleatorio con deriva supone que el esfuerzo de cada año es el del año anterior más una pequeña subida constante (la deriva) y algo de ruido; su error en la prueba es de 0,92 puntos porcentuales, frente a los 1,19 y 1,37 de órdenes con más parámetros. No se usan variantes con variables externas porque, con solo 14 datos, añadir parámetros dispara el riesgo de sobreajuste y obligaría además a proyectar también esas variables. El escenario 2025–2027 (Figura 6) mantiene el esfuerzo en torno al 37 % (37,1 % en 2025, 37,0 % en 2026 y 36,9 % en 2027), siempre por encima del umbral del 30 %, con intervalos al 80 % de 36,0–38,2, 35,4–38,5 y 35,0–38,8 %; esos intervalos son amplios precisamente por lo corta que es la serie, y por eso la salida se presenta como un escenario y no como una predicción exacta.




Figura 6. Escenario de la tasa de esfuerzo 2025–2027 (ARIMA). Fuente: elaboración propia.

5.6. Robustez y adecuación de los modelos

Las métricas de adecuación (el error absoluto medio, la raíz del error cuadrático medio, el error porcentual absoluto medio y el coeficiente de determinación, definidas en el marco teórico) se calculan siempre fuera de muestra y se reportan sin modificarlas para mejorar la cifra. A la selección del modelo se añade un análisis de robustez que responde a una objeción legítima: como el modelo incluye un efecto fijo por provincia, cabe preguntarse si acierta gracias a los determinantes o simplemente porque reconoce a cada provincia. Para despejarlo se comparan tres versiones anidadas, es decir, cada una contenida en la siguiente (Tabla 5): solo con la provincia y la tendencia anual, el R^2 fuera de muestra es 0,805; solo con los determinantes, 0,636; y con las dos cosas a la vez, 0,937. Los determinantes aportan, por tanto, una mejora real de 0,13 puntos sobre la sola identidad de la provincia: el modelo no se limita a saber qué provincias son caras, sino que capta además cómo se mueve el alquiler dentro de cada una.

Tabla 5. Aportación incremental de los determinantes sobre la identidad provincial (R^2 fuera de muestra).

Fuente: elaboración propia.

Especificación	R^2 fuera de muestra
Solo efectos fijos provincia + tendencia anual	0,805
Solo determinantes	0,636
Ambos (modelo final)	0,937
Aporte incremental de los determinantes	+0,132

5.7. Resumen de resultados

Recogidos los cinco análisis, el resultado conjunto se resume así. En la competición predictiva, la regresión Ridge sobre los determinantes gana con claridad (R^2 de 0,937 fuera de muestra, frente a 0,732 y 0,609 de los modelos de árboles), porque en un panel pequeño y con tendencia el modelo sencillo y regularizado generaliza mejor que el complejo. La inferencia con efectos fijos confirma que el determinante más sólido es el volumen de contratos, y el análisis de robustez muestra que los determinantes aportan una mejora real, de 0,13 puntos de R^2 , sobre la mera identidad de cada provincia. El K-Means ordena el territorio en tres tipologías por nivel y dirección del esfuerzo, y revela que el grupo más tensionado, aun con solo diez provincias, concentra a la mitad de los jóvenes del país. Y el escenario ARIMA proyecta la tasa de esfuerzo nacional en torno al 37 % hasta 2027, siempre por encima del umbral del 30 %. Cada uno de estos resultados se acompaña, en su sección, de la figura o la tabla que lo sostiene.

5.8. Interpretación de resultados

La traducción de los hallazgos sigue tres planos. En el diagnóstico, la competición ofrece una conclusión que va más allá del resultado numérico: en un panel pequeño y con tendencia, el modelo sencillo

generaliza mejor que el complejo, no por una limitación del análisis, sino por un rasgo del problema, ya que el alquiler es persistente y su relación con los determinantes es esencialmente lineal. El análisis de robustez matiza esa capacidad explicativa, atribuyendo buena parte del nivel a la identidad provincial y reservando a los determinantes la dinámica dentro de cada territorio.

En el plano del comportamiento, la lectura de los coeficientes estandarizados del modelo final (Figura 4, panel c) ordena la importancia de los determinantes en condiciones comparables, al expresar todas las variables en la misma escala. El volumen de contratos encabeza esa ordenación con claridad, con un peso cercano al doble del siguiente, seguido del salario mínimo; por detrás aparece un bloque de magnitud similar formado por los salarios por edad y el paro. Todos los pesos relevantes son positivos, por lo que el alquiler se asocia con la intensidad de la actividad del mercado y con el nivel salarial y económico del territorio, antes que con un único factor aislado. Esa ordenación debe leerse con la cautela que impone la colinealidad documentada mediante la matriz de correlación (Figura 3) y el factor de inflación de la varianza: las variables salariales comparten información y sus pesos individuales no son separables, por lo que se interpretan como un bloque y no una a una.

La dimensión territorial añade su propia lectura a través de las tipologías del agrupamiento (Figura 5), que no se distinguen solo por el nivel del esfuerzo, sino sobre todo por su dirección. Un grupo reducido de 10 provincias reúne los mercados más caros y tensionados al alza, con un esfuerzo medio del 45,9 % que además crece (+0,25 puntos por año), y agrupa a las grandes metrópolis y los destinos insulares como Madrid, Barcelona o Baleares. Frente a él, una mayoría de 32 provincias se sitúa en torno al 35 % con el esfuerzo levemente a la baja, y un tercer grupo de 6 provincias mantiene un esfuerzo alto, del 43,7 %, pero en claro descenso. La coexistencia de un núcleo que se tensiona con un conjunto amplio que se relaja matiza el diagnóstico agregado y anticipa que la respuesta de negocio no puede ser homogénea en todo el territorio.

Los residuos del modelo son la diferencia entre el alquiler observado y el que el modelo predice a partir de los fundamentales, y tienen lectura propia (Tabla 6). Su distribución no es aleatoria sobre el mapa: el sobreprecio se concentra de forma sistemática en provincias costeras e insulares —encabezadas por Baleares (residuo de +93 €), Málaga (+88 €), Valencia (+52 €) y Santa Cruz de Tenerife (+35 €)—, mientras que el alquiler queda por debajo de lo esperado en provincias del interior como Jaén (−26 €), Ourense (−22 €) o Zamora (−19 €). Esa concentración del sobreprecio en el litoral y las islas es la firma geográfica que cabría esperar de una demanda externa a la renta residente, de carácter turístico o de segunda residencia. El trabajo no la confirma, al no incorporar variables de turismo, pero el patrón es lo bastante sistemático como para señalarla como la explicación más plausible y orientar su verificación futura.

En el plano de la traducción, el diagnóstico es contundente y desigual. La inasequibilidad es casi universal, ya que el 95,8 % de las observaciones provincia-año supera el umbral del 30 %, y en 2022 el 97,9 % de los jóvenes de 18 a 34 años residía en provincias donde la tasa de esfuerzo de la banda de

referencia (26 a 35 años) superaba el 30 %, cifra que mide la exposición territorial al problema y no el número de arrendatarios afectados individualmente. El problema es, además, muy desigual por edad: la banda de 18 a 25 años destina el 71,6 % de su salario al alquiler, frente al 31,2 % de la de 36 a 45.

Tabla 6. Provincias con mayor desviación del alquiler respecto a sus fundamentales (2024). Fuente: elaboración propia.

Provincia	Alquiler real 2024 (€)	Residuo (€)
Balears, Illes	750	93
Málaga	677	88
Valencia/València	570	52
Santa Cruz de Tenerife	550	35
Guadalajara	550	33
Jaén	400	-26
Lugo	370	-24
Ourense	391	-22
Asturias	468	-19
Zamora	399	-19

5.9. Conclusiones del análisis y enlace con el análisis de negocio

El análisis del dato cuantifica el desequilibrio, identifica sus determinantes, ordena el territorio en tipologías y proyecta su evolución, y cada una de esas salidas alimenta una decisión del pilar siguiente. La tasa de esfuerzo y su escenario dimensionan la magnitud y la urgencia del problema, que no mejora por sí solo en el horizonte proyectado. Las tipologías del agrupamiento señalan dónde actuar, al ordenar las provincias por intensidad y dirección del esfuerzo. Los determinantes de la inferencia señalan qué dimensiones conviene considerar en el diagnóstico de negocio, con el volumen de contratos y el salario mínimo como señales relevantes, no como efectos causales identificados. Y los residuos del modelo localizan los mercados recalentados, donde el precio se desvía al alza de sus fundamentales. Esa correspondencia entre salida analítica y decisión es la base sobre la que se construye el análisis de negocio.

Estos hallazgos tienen el alcance que les marca el diseño, sin que ello reste validez a lo encontrado. La proyección se apoya en una serie anual de catorce observaciones, por lo que es un escenario con intervalos amplios y no una predicción exacta. La colinealidad entre las variables salariales obliga a leer sus coeficientes en bloque y no de forma individual. Y, al tratarse de datos observacionales y no incorporar variables de demanda turística ni de oferta de vivienda, el análisis es explicativo-predictivo y no causal: se habla de variables asociadas al alquiler, y la lectura turística de los residuos costeros queda como hipótesis, no como conclusión.

De ahí se derivan las líneas de trabajo futuro. Dos alternativas más avanzadas se valoraron y se descartaron de forma consciente por el tamaño del panel: un estimador dinámico de panel del tipo Arellano-Bond, que sería la referencia si se incluyera el alquiler rezagado pero se vuelve inestable con solo 48 provincias, y una proyección a escala provincial en lugar de nacional, que aprovecharía las 672 observaciones a costa de mucha más complejidad y con la misma serie corta por provincia. Ambas, junto con la incorporación de variables de turismo y de oferta que permitan contrastar la hipótesis de los mercados costeros, quedan como extensiones naturales del trabajo.

El material de esta entrega se publica, bajo control de versiones, en el repositorio del trabajo: <https://github.com/mcdiezderiveradesolis/TFG-Accesibilidad-Vivienda-Joven>. La carpeta del pilar de Análisis del Dato reúne el cuaderno ejecutado, las seis figuras, las cinco tablas en formato Excel y CSV, el script que genera el diagrama metodológico y esta memoria. El panel analizado se construye sobre fuentes oficiales (el alquiler del Sistema Estatal de Referencia del Precio del Alquiler, SERPAVI, del Ministerio de Vivienda y Agenda Urbana; el salario de la población joven de la Agencia Tributaria; el paro de la Encuesta de Población Activa, el índice de precios de consumo y el padrón del Instituto Nacional de Estadística; y el salario mínimo interprofesional del Ministerio de Trabajo y Economía Social), cuyas referencias completas se documentan en el pilar de Ingeniería del Dato.

Declaración sobre el uso de inteligencia artificial (taxonomía CRediT)

En cumplimiento de la normativa de Trabajo Fin de Grado de la Universidad Francisco de Vitoria, se declara el uso de la herramienta de inteligencia artificial Claude (Anthropic) exclusivamente como apoyo durante la elaboración del trabajo. La autora conserva la autoría intelectual y la responsabilidad plena sobre el contenido: la concepción del tema, las decisiones metodológicas, el análisis, la interpretación y las conclusiones son obra suya, y toda salida obtenida con apoyo de la herramienta fue revisada y verificada contra los datos reales antes de incorporarse a la memoria. El uso se detalla por funciones según la taxonomía CRediT.

Rol CRediT	Uso de inteligencia artificial y justificación
Conceptualization · Formal analysis	Sin uso de IA. La concepción del tema y la interpretación de los resultados son de la autora.
Methodology	Consulta de apoyo para aclarar dudas técnicas y contrastar alternativas metodológicas; la elección de cada técnica y de cada supuesto es de la autora.
Software · Data curation	Apoyo en la depuración de código y en tareas instrumentales (como la exportación de resultados); la lógica del análisis y las decisiones sobre los datos son de la autora, que verificó todas las salidas.
Investigation · Validation	Apoyo en la localización y verificación de referencias y en el contraste de coherencia entre código y texto; la validación se realizó sobre los datos y las fuentes originales.
Writing (original draft · review & editing)	Apoyo en la corrección ortográfica y de estilo y en el cumplimiento del formato y la citación (Anexo III, APA 7); las ideas, los argumentos y la redacción son de la autora.
Visualization	Apoyo en la generación y el ajuste estético de las figuras con matplotlib y seaborn; el contenido y la lectura de cada figura son de la autora.
Supervision	No aplica: la dirección académica corresponde al tutor del TFG.

Bibliografía

- Baltagi, B. H. (2008). *Econometric analysis of panel data* (4.^a ed.). Wiley.
- Box, G. E. P., y Jenkins, G. M. (1976). *Time series analysis: Forecasting and control* (ed. rev.). Holden-Day.
- Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2), 123–140. <https://doi.org/10.1007/BF00058655>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Breiman, L., Friedman, J. H., Olshen, R. A., y Stone, C. J. (1984). *Classification and regression trees*. Wadsworth.
- Consejo de la Juventud de España. (2025). *Observatorio de Emancipación de las Personas Jóvenes en España. Segundo semestre de 2024*. <https://www.cje.org/observatorio-de-emancipacion/>
- Dickey, D. A., y Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427–431. <https://doi.org/10.2307/2286348>
- Eurostat. (2024). *Estimated average age of young people leaving the parental household* (yth_demo_030) [Conjunto de datos]. https://ec.europa.eu/eurostat/databrowser/view/yth_demo_030
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The elements of statistical learning* (2.^a ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Hoerl, A. E., y Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67. <https://doi.org/10.1080/00401706.1970.10488634>
- Hyndman, R. J., y Athanasopoulos, G. (2018). *Forecasting: Principles and practice* (2.^a ed.). OTexts. <https://otexts.com/fpp2/>
- Hyndman, R. J., y Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Instituto de la Juventud (INJUVE). (2025). *Informe Juventud en España 2024*. <https://www.injuve.es/observatorio/demografia-e-informacion-general/informe-juventud-en-espana-2024-y-resumen-ejecutivo>
- James, G., Witten, D., Hastie, T., y Tibshirani, R. (2013). *An introduction to statistical learning: With applications in R*. Springer. <https://doi.org/10.1007/978-1-4614-7138-7>
- Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129–137. <https://doi.org/10.1109/TIT.1982.1056489>

- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. En *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* (Vol. 1, pp. 281–297). University of California Press.
- Rosen, S. (1974). Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy*, 82(1), 34–55. <https://doi.org/10.1086/260169>
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- Soltani, A., y Lee, C. L. (2024). The non-linear dynamics of South Australian regional housing markets: A machine learning approach. *Applied Geography*, 166, 103248. <https://doi.org/10.1016/j.apgeog.2024.103248>
- Tchunte, D., y Nyawa, S. (2022). Real estate price estimation in French cities using geocoding and machine learning. *Annals of Operations Research*, 308(1–2), 571–608. <https://doi.org/10.1007/s10479-021-03932-5>
- Tibshirani, R. (1996). Regression shrinkage and selection via the Lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- Wooldridge, J. M. (2010). *Econometric analysis of cross section and panel data* (2.^a ed.). MIT Press.

Fuentes de datos

- Agencia Estatal de Administración Tributaria. (2025). *Mercado de Trabajo y Pensiones en las Fuentes Tributarias. Salario medio por provincia, edad y sexo* (Modelo 190). https://sede.agenciatributaria.gob.es/Sede/datosabiertos/catalogo/hacienda/Mercado_de_Trabajo_y_Pensiones_en_las_Fuentes_Tributarias.shtml
- Instituto Nacional de Estadística. (2025a). *Encuesta de Población Activa. Tasas de actividad, paro y empleo por provincia y sexo* (Tabla 65349). <https://www.ine.es/jaxiT3/Tabla.htm?t=65349>
- Instituto Nacional de Estadística. (2025b). *Índice de Precios de Consumo. Índices por comunidades autónomas: general y de grupos ECOICOP* (Tabla 76136). <https://www.ine.es/jaxiT3/Tabla.htm?t=76136>
- Instituto Nacional de Estadística. (2025c). *Principales series de población desde 1998. Población por provincias, edad, sexo y año*. <https://www.ine.es/jaxi/Tabla.htm?path=/t20/e245/p08/l0/&file=03003.px>
- Ministerio de Trabajo y Economía Social. (2025). *Salario mínimo interprofesional. Serie histórica (SMI-1)*. <https://www.mites.gob.es/estadisticas/bel/SMI/index.htm>
- Ministerio de Vivienda y Agenda Urbana. (2025). *Sistema Estatal de Referencia del Precio del Alquiler de Vivienda (SERPAVI)*. <https://www.mivau.gob.es/vivienda/alquila-bien-es-tu-derecho/serpavi>